

Arquitectura Computacional Basada en Gemelos Digitales para la Optimización del Mantenimiento Predictivo: Una Revisión Sistemática

Espinoza Zuzanibar Michael¹

¹Estudiante De Computación Científica, Universidad Nacional Mayor de San Marcos, Perú

Palabras clave: Gemelo Digital Predictivo, Industria 4.0, Vida Útil Restante, Optimización Algorítmica, Procesamiento de Datos.

RESUMEN: El mantenimiento predictivo (PdM) en entornos industriales ha evolucionado significativamente con la adopción de la industria 4.0, pasando de estrategias reactivas a modelos proactivos. Sin embargo, la gestión, sincronización y procesamiento en tiempo real de grandes volúmenes de datos provenientes de sensores (IoT) representan un desafío computacional crítico. Este artículo propone el diseño de un marco conceptual basado en la tecnología de Gemelos Digitales (Digital Twins) orientado a la optimización del flujo de datos y precisión algorítmica en fábricas inteligentes. A través del análisis de arquitectura de referencia, modelos fundamentados en datos (Data-Driven) y técnicas de simulación avanzada, se evalúa como el procesamiento matemático de las variables permite calcular con alta precisión la Vida Útil Restante (RUL) de los equipos. El enfoque propuesto busca estructurar la información para minimizar la latencia del sistema y facilitar la integración con algoritmos de aprendizaje automático y aprendizaje por refuerzo multiagente. Se concluye que una arquitectura computacional eficiente en el Gemelo Digital no solo viabiliza la detección temprana de anomalías, sino que optimiza la toma de decisiones, reduciendo drásticamente el tiempo de inactividad (downtime) y los costos operativos en la manufactura.

1.- Introducción

La creciente complejidad de los sistemas mecánicos en las industrias modernas ha ampliado la necesidad de estrategias de mantenimiento más eficientes y confiables [4]. Tradicionalmente, los enfoques industriales dependían de intervenciones reactivas o programadas preventivamente, las cuales resultan cada vez más insuficientes frente a la demanda de optimización de costos, rendimiento y tiempo de actividad [4]. En este escenario, el Mantenimiento Predictivo (PdM) se ha posicionado como una solución proactiva que permite pronosticar fallos potenciales y programar intervenciones antes de que ocurran problemas críticos, promoviendo la sostenibilidad al utilizar plenamente los activos sin desperdiciar recursos [4].

Una de las tecnologías habilitadoras clave para la evolución del PdM dentro de la Industria 4.0 es el Gemelo Digital (Digital Twin) [1, 5]. Esta tecnología se conceptualiza como una réplica digital de un objeto, proceso o sistema físico que mantiene una conexión automática y continua mediante un flujo de datos bidireccional [1]. La integración de Gemelos Digitales permite superar los esquemas estáticos al facilitar la visualización, la simulación y el análisis impulsado por datos (Data-Driven) en tiempo real [1].

A pesar de los avances logrados, la implementación computacional de estos sistemas aún enfrenta obstáculos críticos en entornos operativos reales [1, 2]. La literatura existente tiende a estar dispersa en

dominios específicos y carece de un mapeo sistemático que describa de manera holística la arquitectura requerida para estas aplicaciones [1, 2]. A nivel técnico, los modelos de mantenimiento predictivo actuales se ven limitados por problemas de escalabilidad, una alta dependencia de datos limpios provenientes de sensores de la Internet de las Cosas Industrial (IIoT) y dificultades para tomar decisiones autónomas en entornos dinámicos [3].

Ante la necesidad de diseñar marcos conceptuales que estructuren eficientemente el flujo de datos y minimicen la latencia, este artículo de revisión sistemática busca consolidar el estado del arte y proponer un análisis crítico de las soluciones algorítmicas actuales. Para ello, la investigación se fundamenta en las siguientes preguntas de investigación (RQs):

- **RQ1:** ¿Cuáles son las principales aplicaciones y los beneficios estratégicos de la tecnología de Gemelos Digitales para el Mantenimiento Predictivo en entornos de la Industria 4.0? [1].
- **RQ2:** ¿Cómo pueden las arquitecturas computacionales y técnicas avanzadas como el Aprendizaje por Refuerzo Multiagente (MARL) mitigar las limitaciones actuales de escalabilidad, calidad de datos IIoT y adaptación en tiempo real? [3].

2.- Metodología de la Revisión Sistemática

Esta investigación adopta el enfoque de Revisión Sistemática de la Literatura (SLR, por sus siglas en inglés) como diseño principal para la recopilación, selección y análisis computacional de la información [1]. Para garantizar la validez y la confiabilidad del proceso, el estudio se estructura bajo el protocolo PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), lo cual asegura la transparencia en el flujo de búsqueda y minimiza el riesgo de sesgos metodológicos [1].

2.1. Estrategia de Búsqueda

La búsqueda de la literatura se ejecutó de manera estructurada accediendo a bases de datos científicas de reconocido prestigio internacional, específicamente: Scopus, Web of Science (WoS) e IEEE Xplore [1]. Para garantizar que los estudios capturados estuvieran simultáneamente vinculados a los tres ejes de la investigación, se formularon cadenas de búsqueda utilizando operadores booleanos con la siguiente sintaxis: "Digital Twin" AND "Predictive Maintenance" AND "Industry 4.0" [1].

2.2. Criterios de Inclusión y Exclusión

Con el objetivo de obtener estudios de alta calidad y precisión técnica, se definieron los siguientes criterios de inclusión [1]:

- Artículos científicos en formato de artículos de revistas (journals), actas de conferencias (proceedings) y capítulos de libros [1].
- Publicaciones emitidas en el periodo comprendido entre 2018 y 2024, un rango de tiempo que refleja el desarrollo acelerado de la tecnología de Gemelos Digitales junto con los avances en IoT, IA y Big Data [1].
- Estudios que examinen explícitamente la implementación tecnológica en el Mantenimiento Predictivo (PdM) dentro del alcance de la Industria 4.0 [1].

Por otro lado, para mantener el rigor académico y el enfoque del estudio, se establecieron los siguientes criterios de exclusión [1]:

- Documentos no académicos, tales como blogs, reportes de la industria, documentos de divulgación o *white papers* [1].
- Estudios que no posean relevancia directa con el contexto de la Industria 4.0 [1].

- Publicaciones que aborden el concepto de Gemelo Digital pero sin vincularlo específicamente a algoritmos o estrategias de PdM [1].
- Registros duplicados provenientes de las distintas bases de datos [1].

2.3. Proceso de Selección de Estudios (Flujo PRISMA)

La selección y el filtrado de los artículos científicos se desarrolló en fases escalonadas siguiendo las directrices del diagrama de flujo PRISMA, abarcando cuatro etapas fundamentales:

1. **Identificación:** Extracción inicial de todos los documentos y registros desde las bases de datos aplicando las palabras clave definidas [1].
2. **Cribado (Screening):** Evaluación preliminar basada en la lectura de los títulos y resúmenes (abstracts) para descartar los estudios irrelevantes y eliminar los registros duplicados mediante herramientas de automatización [1].
3. **Elegibilidad:** Revisión a texto completo (full-text) de los documentos que superaron el cribado para asegurar el cumplimiento estricto de los criterios de inclusión y su validez académica [1].
4. **Inclusión:** Determinación de los estudios finales que demostraron solidez técnica y que conforman la base para la síntesis de conocimiento y el análisis sistemático [1].

3.- Arquitecturas de Referencia Computacional

Para garantizar la viabilidad y escalabilidad del Mantenimiento Predictivo (PdM) basado en Gemelos Digitales, es imperativo establecer una arquitectura computacional robusta que sirva como plano de diseño o plantilla estandarizada [2]. Esta sección analiza las estructuras fundamentales propuestas en la literatura para organizar los módulos de software, integrar los modelos analíticos y gestionar el flujo de datos industriales en tiempo real [2].

3.1. La Arquitectura 5C

La arquitectura en capas 5C se ha consolidado como un estándar para el diseño jerárquico de Sistemas Ciberfísicos (CPS) y Gemelos Digitales [2]. Esta estructura impone una comunicación unidireccional permitida entre niveles adyacentes y organiza los componentes del sistema en cinco fases computacionales [2]:

- **Conexión (Connection):** Constituye la base de la arquitectura, siendo responsable de la interacción con el gemelo físico, la adquisición de datos (en lotes o flujos continuos), el almacenamiento temporal o persistente y la ejecución de protocolos de comunicación [2].
- **Conversión (Conversion):** Gestiona la seguridad informática de las transmisiones y la gestión de la calidad de los datos, aplicando algoritmos de limpieza y enriquecimiento para mitigar el ruido y los errores de los sensores [2].
- **Cibernética (Cyber):** Aloja los modelos de simulación matemática del activo, los cuales pueden ser fundamentados en física, basados en datos (Data-Driven), de comportamiento o representaciones geométricas, adaptándose al nivel de abstracción requerido por el componente o sistema [2].

- **Cognición (Cognition):** Proporciona las interfaces de visualización y el núcleo de análisis de datos, siendo la capa exacta donde reside la lógica algorítmica del módulo de mantenimiento predictivo [2].
- **Configuración (Configuration):** Es la capa superior que emplea los conocimientos analíticos procesados en la capa cognitiva para ejecutar la optimización de la máquina y retroalimentar de manera autónoma al sistema físico [2].

3.2. Vistas de Arquitectura de Software

El desarrollo de un sistema de Gemelo Digital complejo requiere un enfoque de diseño estructurado que aborde los requisitos mediante diferentes vistas arquitectónicas en lenguaje de modelado unificado (UML) [2]:

- **Vista de Usuario (Diagrama de Contexto):** Describe las interfaces de alto nivel del sistema, modelando cómo fluyen los datos bidireccionales desde los sensores físicos y recursos de computación en la nube hacia el Gemelo Digital, y cómo los conocimientos analíticos resultantes se dirigen a los actuadores mecánicos o supervisores humanos [2].
- **Vista Estructural (Diagrama de Paquetes):** Define la organización modular del software, agrupando lógicamente operaciones críticas como el preprocesamiento, la validación de modelos, la extracción de características en dominios de tiempo/frecuencia y la evaluación de métricas de rendimiento de algoritmos (*Machine Learning*) [2].
- **Vista de Despliegue:** Describe la distribución de los nodos de hardware y software en el entorno operativo. Es un elemento crucial para separar computacionalmente los subsistemas físicos (dispositivos de adquisición instalados en las fábricas) de los servidores remotos o entornos de ejecución en la nube donde se computa el Gemelo Digital [2].

3.3. Gestión de Datos IIoT y Sincronización en Tiempo Real

El rendimiento de cualquier modelo matemático de mantenimiento predictivo depende críticamente de la gestión eficiente de los datos provenientes de la Internet de las Cosas Industrial (IIoT) [2, 3]. Los sensores distribuidos físicamente a lo largo de los activos capturan en tiempo real parámetros operativos fundamentales como la vibración, la temperatura y la presión del equipo [2, 3].

Sin embargo, los entornos industriales dinámicos generan datos crudos que a menudo presentan ruido, valores faltantes, errores de sensor y problemas de latencia en la comunicación de red [2, 3]. Para superar este desafío computacional, la arquitectura del sistema debe incorporar una capa de preprocesamiento de datos iterativa que filtre y depure la información antes de su uso analítico [2]. Estos datos procesados se retroalimentan de manera continua al Gemelo Digital, garantizando una sincronización precisa y permitiendo que los algoritmos predictivos operen sobre el estado más actualizado y fidedigno del activo físico [2, 3].

4.- Optimización Algorítmica y Modelos Fundamentados en Datos (Data-Driven)

El núcleo analítico de un Gemelo Digital orientado al Mantenimiento Predictivo (PdM) reside en su capacidad para procesar grandes volúmenes de datos mediante modelos matemáticos y estadísticos avanzados. Esta sección revisa los enfoques algorítmicos predominantes utilizados para pronosticar fallos y optimizar las operaciones industriales en tiempo real [1, 2].

4.1. Estimación de la Vida Útil Restante (RUL)

El cálculo de la Vida Útil Restante (RUL, por sus siglas en inglés) es la métrica fundamental del mantenimiento predictivo. El RUL estima el tiempo o uso que le queda a un componente antes de que deje de funcionar de manera efectiva. Para lograr esta predicción, los Gemelos Digitales aprovechan datos históricos, entradas en tiempo real de los sensores y simulaciones operativas, lo que permite identificar patrones y anomalías que podrían señalar una falla inminente. A través del análisis de tendencias de datos, los algoritmos de aprendizaje automático (*Machine Learning*) pueden pronosticar cuándo es probable que un equipo falle, permitiendo a los equipos de mantenimiento intervenir antes de que se produzcan tiempos de inactividad costosos. A medida que estos modelos procesan más información, mejoran continuamente su capacidad para predecir fallos con mayor precisión [1, 2].

4.2. Evaluación de Modelos de Aprendizaje Automático (Machine Learning)

La precisión de un Gemelo Digital fundamentado en datos depende directamente de la selección del algoritmo de *Machine Learning* adecuado. La literatura reciente demuestra la importancia de comparar la eficacia de diversos modelos de regresión dentro de un entorno de manufactura inteligente. En procesos de torneado CNC, por ejemplo, se han entrenado modelos predictivos utilizando algoritmos como Regresión Lineal, *Random Forest*, *XGBoost*, *AdaBoost*, Máquinas de Vectores de Soporte (SVR) y Perceptrón Multicapa (MLP) [5].

Los análisis estadísticos revelan que el rendimiento de los algoritmos varía según la variable de respuesta [5]:

- **Predicción de la Rugosidad Superficial:** El algoritmo *Random Forest Regressor* ha demostrado ser el modelo más eficaz, logrando el coeficiente de determinación (R^2) más alto ($94.2\% \pm 2.4\%$) y el error absoluto medio (MAE) más bajo al utilizar la velocidad de corte, la tasa de avance y la profundidad de corte como parámetros de entrada. Esto permite optimizar los parámetros de la máquina para garantizar un acabado superficial de alta calidad [5].
- **Predicción del Consumo de Energía:** Para variables críticas como el consumo de energía (derivado de la fuerza y velocidad de corte), el algoritmo *XGB Regressor* presenta el mejor rendimiento predictivo, alcanzando un R^2 de $98.9\% \pm 0.5\%$. La integración de este algoritmo en el Gemelo Digital facilita la reducción del uso de energía, promoviendo una producción más sostenible y rentable [5].

4.3. Aprendizaje por Refuerzo Multiagente (MARL) para la Toma de Decisiones

A pesar de la precisión de los modelos de *Machine Learning* tradicionales, estos a menudo asumen la disponibilidad de datos limpios y pueden carecer de la flexibilidad necesaria para tomar decisiones autónomas en lazo cerrado durante la operación en tiempo real. Para abordar estos desafíos de escalabilidad y adaptabilidad, se ha propuesto la integración del Aprendizaje por Refuerzo Multiagente (MARL, por sus siglas en inglés) en la arquitectura del Gemelo Digital [3].

En este enfoque, el sistema se compone de varios agentes independientes, donde existe una correspondencia uno a uno entre los agentes y los componentes del sistema físico. Estos agentes interactúan con el Gemelo Digital y reciben recompensas en función de qué tan bien optimizan las decisiones de mantenimiento, tales como predecir fallos inminentes, programar el mantenimiento preventivo y coordinar las reparaciones. La principal ventaja de los sistemas MARL es su capacidad para aprender, adaptarse y optimizar estrategias a partir de conjuntos de datos provenientes del IIoT que pueden ser ruidosos, incompletos o corruptos en tiempo real. Esto no solo disminuye la dependencia de datos exhaustivamente etiquetados, sino que asegura la disponibilidad operativa en condiciones industriales inciertas y dinámicas [3].

5.- Aplicaciones en la Industria 4.0 y Sistemas Mecánicos

El despliegue del Mantenimiento Predictivo basado en Gemelos Digitales (PdMDT) ha transformado radicalmente la gestión de los activos mecánicos en múltiples sectores de la Industria 4.0. Al proporcionar una réplica virtual que procesa datos en tiempo real, esta tecnología ha demostrado su viabilidad en la optimización de maquinaria compleja en entornos exigentes. A continuación, se detallan las aplicaciones más relevantes documentadas en la literatura [1, 4].

5.1. Robótica Industrial y Sistemas Electroópticos

En el sector de la manufactura avanzada, el PdMDT es fundamental para el monitoreo de robots industriales sometidos a uso constante. Un caso de aplicación documentado es el cálculo de la Vida Útil Restante (RUL) en robots de seis ejes utilizados para tareas de soldadura. A través de simulaciones basadas en la física y señales de posición y torque en tiempo real, el Gemelo Digital evalúa el estado de las cajas de engranajes, permitiendo ajustar los programas de mantenimiento dinámicamente y evitando averías inesperadas [4].

Por otro lado, en aplicaciones aeroespaciales y de defensa, los Gemelos Digitales se emplean para monitorear el estado de salud de sistemas de imágenes electroópticas. Dado que la calidad de imagen de estos dispositivos se deteriora significativamente ante fallos mecánicos o de calibración, se utilizan modelos híbridos (que combinan modelos físicos con redes bayesianas fundamentadas en datos) para rastrear la degradación del sistema y garantizar la probabilidad de detección de objetivos [4].

5.2. Turbinas Eólicas Flotantes Marinas

En la infraestructura energética, los sistemas de transmisión de las turbinas eólicas flotantes marinas (FWT) operan bajo fuerzas dinámicas extremas generadas por el viento y el oleaje, lo que los hace altamente propensos a fallos. En este contexto, se implementan Gemelos Digitales basados en modelos torsionales con múltiples grados de libertad que imitan el comportamiento del sistema de transmisión en tiempo real. Estos modelos analizan las mediciones de vibración para estimar las tensiones de contacto y el daño por fatiga acumulado en los engranajes, permitiendo intervenciones oportunas que previenen paradas catastróficas [4].

5.3. Operaciones de Torneado CNC y Sostenibilidad

En el mecanizado de precisión, la tecnología de Gemelos Digitales impulsados por datos se utiliza para predecir condiciones críticas de la herramienta y optimizar los parámetros del proceso. Específicamente en operaciones de torneado CNC, la implementación de algoritmos de *Machine Learning* dentro del marco del Gemelo Digital ha permitido predecir con gran exactitud la rugosidad superficial de las piezas maquinadas y el consumo de energía del equipo. Esta aplicación técnica es vital, ya que predecir la rugosidad garantiza productos personalizados de alta calidad, mientras que la optimización del consumo de potencia fomenta una producción mucho más sostenible, reduciendo el uso de energía y los costos asociados [5].

5.4. Reducción Cuantitativa del *Downtime* y Costos Operativos

El impacto transversal de todas estas aplicaciones mecánicas se traduce directamente en la eficiencia financiera y operativa de las fábricas. La implementación de un marco de Gemelo Digital, especialmente cuando se potencia con Aprendizaje por Refuerzo Multiagente (MARL), ha demostrado una reducción drástica y cuantitativa del tiempo de inactividad no planificado (*downtime*). A través de la toma de decisiones autónoma para la programación de intervenciones, los sistemas basados en MARL logran una reducción sustancial de los costos de mantenimiento al compararse con los enfoques reactivos tradicionales y los modelos estáticos de aprendizaje automático [1, 3].

6.- Discusión, Retos Abiertos y Trabajo Futuro

A pesar de los claros beneficios operativos demostrados, la implementación de la arquitectura computacional del Mantenimiento Predictivo basado en Gemelos Digitales (PdMDT) enfrenta importantes desafíos técnicos y económicos que deben resolverse para lograr una adopción industrial masiva [1, 4].

6.1. Desafíos de Infraestructura y Costos

Uno de los principales obstáculos para la adopción del PdMDT es la alta inversión inicial requerida. Las organizaciones deben invertir en hardware (sensores IIoT), infraestructura de red, software especializado y recursos de computación en la nube. Además, el desarrollo de Gemelos Digitales precisos y funcionales es un proceso complejo que exige conocimientos especializados en modelado matemático, ciencia de datos y la integración de sistemas de tecnologías de la información (TI) con tecnologías operativas (OT) [3, 4].

6.2. Calidad de los Datos y Ciberseguridad

El manejo de los grandes volúmenes de datos en tiempo real generados por la red IIoT representa un desafío crítico. Los sistemas deben ser lo suficientemente robustos para capturar, almacenar y procesar esta información de manera efectiva, lidiar con datos ruidosos o incompletos y evitar que los errores de los sensores interrumpan la toma de decisiones del sistema predictivo [3, 4].

Adicionalmente, la dependencia de la conectividad en tiempo real y la computación en la nube introduce severas vulnerabilidades de ciberseguridad. Los dispositivos IoT a menudo carecen de la robustez de los sistemas de TI tradicionales, lo que los convierte en objetivos potenciales para ataques cibernéticos que podrían comprometer la integridad de los datos de mantenimiento o revelar información industrial confidencial. Las empresas tecnológicas deben considerar incrustar el software predictivo directamente en la máquina (procesamiento local o *edge computing*) para limitar el flujo de datos susceptibles de ser interceptados [4].

6.3. Trabajo Futuro y Líneas de Investigación

Para superar las limitaciones actuales, la literatura sugiere varias direcciones para investigaciones futuras:

- **Modelos de Retorno de Inversión (ROI):** Es imperativo desarrollar marcos sistemáticos para calcular el ROI y la eficiencia de costos de la implementación del PdMDT, proporcionando una justificación económica sólida para las decisiones gerenciales [1].
- **Integración Profunda de la Inteligencia Artificial:** Se requiere investigar más a fondo la integración de IA en los sistemas DTT para mejorar el mantenimiento autónomo, implementar analítica prescriptiva y lograr predicciones que se adapten a la dinámica operativa [1, 4].
- **Modelos Temporales y Adaptativos:** Gran parte de los modelos de *Machine Learning* actuales se basan en datos experimentales estáticos que no capturan las dependencias temporales inherentes a los entornos dinámicos de manufactura. El trabajo futuro debe incorporar sistemas de adquisición en tiempo real y bases de datos de series temporales para desarrollar modelos predictivos conscientes del tiempo [5].
- **Marcos de Seguridad de Datos:** Es necesario explorar el diseño de arquitecturas de protección de datos, políticas de seguridad y estándares criptográficos que garanticen la fiabilidad de los Gemelos Digitales frente a amenazas informáticas [1].

7.- Conclusión

La integración tecnológica de los Gemelos Digitales en el mantenimiento de sistemas mecánicos representa un cambio de paradigma en la Industria 4.0, transformando las estrategias reactivas en un Mantenimiento Predictivo (PdM) altamente eficiente. Esta revisión sistemática evidencia que una arquitectura computacional robusta —como la estructurada en el modelo 5C— es fundamental para gestionar el flujo bidireccional de datos en tiempo real entre los activos físicos y sus réplicas virtuales [1, 2, 4].

Los modelos fundamentados en datos (*Data-Driven*), impulsados por algoritmos de *Machine Learning*, han demostrado una notable eficacia matemática para calcular la Vida Útil Restante (RUL), optimizar parámetros de calidad como la rugosidad superficial y reducir el consumo energético en los equipos de manufactura. Asimismo, la integración de técnicas avanzadas como el Aprendizaje por Refuerzo Multiagente (MARL) emerge como una solución crítica para superar las limitaciones de escalabilidad y datos ruidosos de sensores IoT, dotando al sistema de capacidades de toma de decisiones autónoma y adaptativa [3, 5].

Aunque los desafíos de inversión inicial, infraestructura de datos y ciberseguridad continúan siendo factores limitantes, la literatura confirma que el Gemelo Digital es un facilitador indispensable para maximizar la disponibilidad de la maquinaria, reducir drásticamente los tiempos de inactividad no planificados y optimizar los costos operativos en la manufactura inteligente moderna [1, 4].

8.- Referencias

- [1] L. Judijanto, "Digital Twin Technology for Predictive Maintenance in Industry 4.0: A Systematic Review," *Science and Applied Journal (SIAP)*, vol. 2, no. 1, pp. 85-97, 2025.
- [2] R. van Dinter, B. Tekinerdogan, y C. Catal, "Reference architecture for digital twin-based predictive maintenance systems," *Computers & Industrial Engineering*, vol. 177, p. 109099, 2023.
- [3] R. S. Garapati y S. K. R. Kanna, "A Digital Twin-Enabled Predictive Maintenance Framework Leveraging Multi-Agent Reinforcement Learning and Industrial IoT Data," en *Proceedings of the 1st International Conference on Intelligent Methods and Advanced Computer Scientific Innovations (IMACSI 2025)*, vol. 1, pp. 17-23, 2025.
- [4] L. Mešeljević y F. Hadžikadunić, "Applications of Digital Twins in Predictive Maintenance of Mechanical Systems," en *8th research-expert conference with international participation "MAINTENANCE 2024"*, Zenica, B&H, 2024.
- [5] T. Khan, U. Khan, A. Khan, C. Mollan, I. Morkvenaite-Vilkonciene, y V. Pandey, "Data-Driven Digital Twin Framework for Predictive Maintenance of Smart Manufacturing Systems," *Machines*, vol. 13, no. 6, p. 481, 2025.